

# Contrastes de hipótesis

## Contents

<b>1</b>	<b>Contrastes para las <math>\beta_i</math> usando la distribución <i>t-student</i></b>	<b>1</b>
1.1	Teoría . . . . .	1
1.2	Ejemplo . . . . .	2
<b>2</b>	<b>Relación entre intervalos de confianza y contrastes</b>	<b>3</b>
<b>3</b>	<b>Contraste para <math>\sigma^2</math></b>	<b>4</b>
<b>4</b>	<b>Contraste de regresión múltiple</b>	<b>4</b>
4.1	La distribución $F$ . . . . .	4
4.2	Descomposición de la variabilidad . . . . .	5
4.3	Contraste . . . . .	5
4.4	Ejemplo . . . . .	6
<b>5</b>	<b>Contraste para un grupo de coeficientes</b>	<b>6</b>
5.1	Ejemplo: contraste para un regresor . . . . .	7
5.2	Ejemplo: el contraste de regresión múltiple . . . . .	8
5.3	Ejemplo: contraste sobre una pareja de regresores . . . . .	8
5.4	Ejemplo: contraste de igualdad de regresores . . . . .	9

## 1 Contrastes para las $\beta_i$ usando la distribución *t-student*

### 1.1 Teoría

Queremos resolver los contrastes:

$$H_0 : \beta_i = 0 \quad H_1 : \beta_i \neq 0$$

para el modelo  $y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$ . Hemos visto que

$$\frac{\hat{\beta}_i - \beta_i}{se(\hat{\beta}_i)} \rightarrow t_{n-k-1}$$

Por tanto, si  $H_0$  es cierta:

$$t_0 = \frac{\hat{\beta}_i}{se(\hat{\beta}_i)} \rightarrow t_{n-k-1}$$

Sea  $t_{n-k-1;\alpha/2}$  el valor de una t-student con  $(n-k-1)$  grados de libertad tal que

$$P(t_{n-k-1} \geq t_{n-k-1;\alpha/2}) = \alpha/2$$

- si  $|t_0| \geq t_{n-k-1;\alpha/2}$ : se rechaza  $H_0$

- si  $|t_0| \leq t_{n-k-1; \alpha/2}$ : no se rechaza  $H_0$

Se define el *pvalor* como:

$$pvalor = 2P(t_{n-k-1} \geq |t_0|)$$

Por tanto

- si  $pvalor \leq \alpha$ : se rechaza  $H_0$
- si  $pvalor \geq \alpha$ : no se rechaza  $H_0$

## 1.2 Ejemplo

Veamos por ejemplo el modelo  $kid\_score \sim mom\_hs + mom\_iq + mom\_age$ :

```
d = read.csv("datos/kidiq.csv")
d$mom_hs = factor(d$mom_hs, labels = c("no", "si"))
d$mom_work = factor(d$mom_work, labels = c("notrabaja", "trabaja23", "trabaja1_parcial", "trabaja1_comp"))

m1 = lm(kid_score ~ . - mom_work, data = d)
summary(m1)
```

```
##
## Call:
## lm(formula = kid_score ~ . - mom_work, data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -53.289 -12.421   2.399  11.223  50.169
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  20.98466    9.13013   2.298  0.0220 *
## mom_hssi     5.64715    2.25766   2.501  0.0127 *
## mom_iq       0.56254    0.06065   9.276 <2e-16 ***
## mom_age      0.22475    0.33075   0.680  0.4972
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.15 on 430 degrees of freedom
## Multiple R-squared:  0.215, Adjusted R-squared:  0.2095
## F-statistic: 39.25 on 3 and 430 DF, p-value: < 2.2e-16
```

Veamos de donde salen los valores de la tabla anterior:

- Estimate:

```
(beta_e = coefficients(m1))
```

```
## (Intercept)      mom_hssi      mom_iq      mom_age
##  20.9846620    5.6471512    0.5625443    0.2247505
```

- Std. Error:

```
(beta_se = sqrt(diag(vcov(m1))))
```

```
## (Intercept)      mom_hssi      mom_iq      mom_age
##  9.13012544    2.25765592    0.06064506    0.33074520
```

- t value:

```
(t_value = beta_e/beta_se)
```

```
## (Intercept)      mom_hssi      mom_iq      mom_age
##    2.2983980    2.5013339    9.2760110    0.6795276
```

- $\Pr(>|t|)$  (es decir, p-valores):

```
n = nrow(d)
k = 3
(pvalores = 2*pt(abs(t_value), df = n - k -1, lower.tail = F))
```

```
## (Intercept)      mom_hssi      mom_iq      mom_age
## 2.201813e-02 1.274346e-02 8.650677e-19 4.971693e-01
```

- Si juntamos todo en una tabla:

```
data.frame(beta_e, beta_se, t_value, pvalores)

##           beta_e      beta_se    t_value      pvalores
## (Intercept) 20.9846620 9.13012544 2.2983980 2.201813e-02
## mom_hssi     5.6471512 2.25765592 2.5013339 1.274346e-02
## mom_iq       0.5625443 0.06064506 9.2760110 8.650677e-19
## mom_age      0.2247505 0.33074520 0.6795276 4.971693e-01
```

## 2 Relación entre intervalos de confianza y contrastes

En el caso de contrastes bilaterales:

$$H_0 : \beta_i = 0 \quad H_1 : \beta_i \neq 0$$

Y con intervalo de confianza:

$$\beta_i \in (a_i, b_i)$$

- Si  $0 \in (a_i, b_i) \Rightarrow$  no se rechaza  $H_0$ .
- Si  $0 \notin (a_i, b_i) \Rightarrow$  se rechaza  $H_0$ .

En el caso del ejemplo, si miramos pvalores e intervalos:

```
confint(m1)

##           2.5 %      97.5 %
## (Intercept) 3.0394352 38.9298887
## mom_hssi    1.2097371 10.0845653
## mom_iq      0.4433466 0.6817419
## mom_age     -0.4253280 0.8748289

summary(m1)

##
## Call:
## lm(formula = kid_score ~ . - mom_work, data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -53.289 -12.421   2.399  11.223  50.169
```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) 20.98466    9.13013   2.298  0.0220 *
## mom_hssi     5.64715    2.25766   2.501  0.0127 *
## mom_iq       0.56254    0.06065   9.276 <2e-16 ***
## mom_age      0.22475    0.33075   0.680  0.4972
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.15 on 430 degrees of freedom
## Multiple R-squared:  0.215, Adjusted R-squared:  0.2095
## F-statistic: 39.25 on 3 and 430 DF, p-value: < 2.2e-16
```

### 3 Contraste para $\sigma^2$

El contraste es:

$$H_0 : \sigma^2 = \sigma_0^2 \quad H_1 : \sigma^2 \neq \sigma_0^2$$

El estadístico del contraste que vamos a utilizar es:

$$\frac{(n-k-1)\hat{s}_R^2}{\sigma^2} \rightarrow \chi_{n-k-1}^2$$

Por tanto, si la hipótesis nula es cierta,

$$\chi_0^2 = \frac{(n-k-1)\hat{s}_R^2}{\sigma_0^2} \rightarrow \chi_{n-k-1}^2$$

Como ejemplo, vamos a contrastar

$$H_0 : \sigma^2 = 20^2 \quad H_1 : \sigma^2 \neq 20^2$$

```
(chisq_0 = sum(resid(m1)^2)/20^2)

## [1] 354.0126
# límites del contraste bilateral
c(qchisq(0.05/2,df = n-k-1), qchisq(1-0.05/2,df = n-k-1))

## [1] 374.4397 489.3477
```

Por tanto se rechaza la hipótesis nula. El mismo resultado se obtiene mirando el intervalo de confianza.

## 4 Contraste de regresión múltiple

### 4.1 La distribución $F$

Sean una  $\chi_m^2$  y una  $\chi_n^2$ , ambas independientes. La distribución  $F$  se define como

$$\frac{\chi_m^2/m}{\chi_n^2/n} \sim F_{m,n}$$

## 4.2 Descomposición de la variabilidad

Tenemos el modelo

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_k x_{ki} + e_i = \hat{y}_i + e_i$$

Restando la media  $\bar{y} = \sum y_i/n$ :

$$y_i - \bar{y} = \hat{y}_i - \bar{y} + e_i$$

Elevando al cuadrado y sumando se tiene:

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum e_i^2$$

ya que  $\sum (\hat{y}_i - \bar{y})e_i = 0$ . Se denominan:

- Variabilidad total:

$$VT = \sum (y_i - \bar{y})^2 = (n-1)\hat{s}_y^2$$

- Variabilidad explicada:

$$VE = \sum (\hat{y}_i - \bar{y})^2$$

- Variabilidad no explicada o residual:

$$VNE = \sum e_i^2 = (n-k-1)\hat{s}_R^2$$

## 4.3 Contraste

Es el contraste más importante en regresión múltiple, ya que establece si alguno de los regresores influye en la respuesta. Es decir, en el modelo  $y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$  se contrasta si

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0 \quad H_1 : \text{Algún } \beta_i \neq 0$$

Para resolver este contraste, se puede demostrar que:

- Si  $\beta_1 = \beta_2 = \cdots = \beta_k = 0 \Rightarrow VE/\sigma^2 \sim \chi_k^2$
- $VNE/\sigma^2 \sim \chi_{n-k-1}^2$
- VE y VNE son independientes.

Por lo tanto es razonable utilizar el estadístico:

$$\frac{\frac{VE/\sigma^2}{k}}{\frac{VNE/\sigma^2}{n-k-1}} \sim F_{k,n-k-1} \Rightarrow F_0 = \frac{VE/k}{VNE/(n-k-1)} \sim F_{k,n-k-1}$$

Se rechazará la hipótesis nula para valores grandes del estadístico:

- si  $F_0 > F_\alpha$ : se rechaza  $H_0$
- si  $F_0 \leq F_\alpha$ : no se rechaza  $H_0$

## 4.4 Ejemplo

Queremos contrastar si  $\beta_{mom\_age} = \beta_{mom\_hs} = \beta_{mom\_iq} = 0$  en el modelo  $kid\_score \sim mom\_hs + mom\_iq + mom\_age$ , es decir, si estos regresores influyen en la puntuación obtenida en el test.

```
(VT = sum((d$kid_score - mean(d$kid_score))^2) )

## [1] 180386.2
(VNE = sum(resid(m1)^2))

## [1] 141605
(VE = VT - VNE)

## [1] 38781.13
(F_0 = VE/k/(VNE/(n-k-1)))

## [1] 39.25446
(F_alfa = qf(0.05, df1 = k, df2 =n-5-1))

## [1] 0.1171935
# pvalor
1 - pf(F_0, k, n-k-1)

## [1] 0
• En R:
summary(m1)

##
## Call:
## lm(formula = kid_score ~ . - mom_work, data = d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -53.289 -12.421   2.399  11.223  50.169
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  20.98466    9.13013   2.298  0.0220 *
## mom_hssi     5.64715    2.25766   2.501  0.0127 *
## mom_iq       0.56254    0.06065   9.276 <2e-16 ***
## mom_age      0.22475    0.33075   0.680  0.4972
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.15 on 430 degrees of freedom
## Multiple R-squared:  0.215, Adjusted R-squared:  0.2095
## F-statistic: 39.25 on 3 and 430 DF, p-value: < 2.2e-16
```

Luego se rechaza la hipótesis nula, y al menos uno de los regresores influye en *kid\_score*.

## 5 Contraste para un grupo de coeficientes

Consideremos el modelo de regresión con  $k$  regresores:

$$y = X\beta + u, \dim(\beta) = k \times 1$$

Y consideremos otro modelo de regresión en el que se utilizan  $m$  de los  $k$  regresores:

$$y = X'\beta' + u', \dim(\beta') = m \times 1$$

Sea  $VNE(k)$  la variabilidad no explicada del primer modelo, y  $VNE(m)$  la variabilidad no explicada del segundo modelo. Se puede demostrar que:

$$F_0 = \frac{(VNE(m) - VNE(k))/(k - m)}{VNE(k)/(n - k - 1)} \sim F_{k-m, n-k-1}$$

Con este estadístico podemos resolver el contraste

$$H_0 : \text{Los modelos son iguales} \quad H_1 : \text{Los modelos NO son iguales}$$

Si el estadístico toma valores pequeños quiere decir que la varianza residual es parecida en ambos modelos, luego se considera que los modelos son equivalentes. Por tanto, se rechazará la hipótesis nula para valores grandes del estadístico:

- si  $F_0 > F_\alpha$ : se rechaza  $H_0$
- si  $F_0 \leq F_\alpha$ : no se rechaza  $H_0$

## 5.1 Ejemplo: contraste para un regresor

Vamos a analizar si el regresor `mom_age` puede eliminarse de la lista. El contraste que resolvemos es  $H_0 : \beta_{mom\_age} = 0$  en el modelo `kid_score ~ mom_hs + mom_iq + mom_age`. Para ello lo comparamos con el modelo `kid_score ~ mom_hs + mom_iq`. Si los modelos son equivalentes quiere decir que  $\beta_{mom\_age} = 0$ :

```
m2 = lm(kid_score ~ mom_hs + mom_iq, data = d)
(VNE2 = sum(resid(m2)^2))
```

```
## [1] 141757.1
```

```
m = 2
(F_0 = ((VNE2 - VNE)/(k-m))/(VNE/(n-k-1)))
```

```
## [1] 0.4617577
```

```
# F_alfa
qf(0.95, k-m, n-k-1)
```

```
## [1] 3.863175
```

```
# pvalor
1-pf(F_0, k-m, n-k-1)
```

```
## [1] 0.4971693
```

Luego no se puede rechazar la hipótesis nula (los modelos son iguales), luego el regresor `mom_age` se puede eliminar del modelo. Se obtiene el mismo resultado que con el contraste de la t-student.

- Con R:

```
anova(m2, m1)
```

```
## Analysis of Variance Table
##
## Model 1: kid_score ~ mom_hs + mom_iq
## Model 2: kid_score ~ (mom_hs + mom_iq + mom_work + mom_age) - mom_work
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1     431 141757
## 2     430 141605   1    152.06 0.4618 0.4972
```

## 5.2 Ejemplo: el contraste de regresión múltiple

El contraste de regresión múltiple ( $H_0 : \beta_{mom\_hs} = \beta_{mom\_iq} = \beta_{mom\_age} = 0$ ) también se puede resolver utilizando este estadístico. Los dos modelos a comparar son:  $kid\_score \sim 1 + mom\_hs + mom\_iq + mom\_age$  y  $kid\_score \sim 1$ . El 1 hace referencia al  $\beta_0$ , y se estima por defecto si no se indica explícitamente:

```
m3 = lm(kid_score ~ 1, d)
```

Por tanto

```
anova(m3, m1)
```

```
## Analysis of Variance Table
##
## Model 1: kid_score ~ 1
## Model 2: kid_score ~ (mom_hs + mom_iq + mom_work + mom_age) - mom_work
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1     433 180386
## 2     430 141605   3    38781 39.255 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

## 5.3 Ejemplo: contraste sobre una pareja de regresores

El contraste que resolvemos es  $H_0 : \beta_{mom\_iq} = \beta_{mom\_age} = 0$  en el modelo  $kid\_score \sim mom\_hs + mom\_iq + mom\_age$ . Para ello lo comparamos con el modelo:

```
m4 = lm(kid_score ~ mom_hs, data = d)
(VNE4 = sum(resid(m4)^2))
```

```
## [1] 170261.2
```

```
m = 1
```

```
(F_0 = ((VNE4 - VNE)/(k-m))/(VNE/(n-k-1)))
```

```
## [1] 43.50887
```

```
# F_alfa
```

```
qf(0.05, k-m, n-k-1)
```

```
## [1] 0.05129941
```

```
# pvalor
```

```
1-pf(F_0, k-m, n-k-1)
```

```
## [1] 0
```

Luego se rechaza la hipótesis nula.

- Con R:

```
anova(m4, m1)
```



```
## Analysis of Variance Table
##
## Model 1: kid_score ~ mom_hs
## Model 2: kid_score ~ (mom_hs + mom_iq + mom_work + mom_age) - mom_work
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      432 170261
## 2      430 141605   2    28656 43.509 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

## 5.4 Ejemplo: contraste de igualdad de regresores

El contraste que resolvemos es  $H_0 : \beta_{mom\_iq} = \beta_{mom\_age}$  en el modelo  $kid\_score \sim mom\_hs + mom\_iq + mom\_age$ . Hacemos la comparación con el modelo:

```
m5 = lm(kid_score ~ mom_hs + I(mom_iq + mom_age), data = d)
(VNE5 = sum(resid(m5)^2))
```

```
## [1] 141933.5
```

```
m = 2
(F_0 = ((VNE5 - VNE)/(k-m))/(VNE/(n-k-1)))
```

```
## [1] 0.9974542
```

```
# pvalor
1-pf(F_0, k-m, n-k-1)
```

```
## [1] 0.318489
```

OJO, el modelo m5 es:

$$kid\_score_i = \beta_0 + \beta_1 mom\_hs_i + \beta_2 mom\_iq_i + \beta_3 mom\_age_i + u_i$$

- En R:

```
anova(m5,m1)
```

```
## Analysis of Variance Table
##
## Model 1: kid_score ~ mom_hs + I(mom_iq + mom_age)
## Model 2: kid_score ~ (mom_hs + mom_iq + mom_work + mom_age) - mom_work
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      431 141934
## 2      430 141605   1    328.48 0.9975 0.3185
```

Como vemos no se puede rechazar la hipótesis nula *Los modelos son iguales*, luego no se puede rechazar  $H_0 : \beta_{mom\_iq} = \beta_{mom\_age}$ .

Por último vamos a resolver este contraste con la t-student. El modelo m1 es

$$kid\_score = \beta_0 + \beta_1 mom\_hssi + \beta_2 mom\_iq + \beta_3 mom\_age + u$$

La hipótesis nula del contraste es:  $H_0 : \beta_2 = \beta_3$ . Para encontrar el estadístico del contraste tenemos que:

$$\hat{\beta}_2 \sim N(\beta_2, \sigma^2 \tilde{Q}_{3,3}), \quad \hat{\beta}_3 \sim N(\beta_3, \sigma^2 \tilde{Q}_{4,4})$$

Por tanto:

$$\hat{\beta}_2 - \hat{\beta}_3 \sim N(\beta_2 - \beta_3, \sigma^2(\tilde{Q}_{3,3} + \tilde{Q}_{4,4} - 2\tilde{Q}_{3,4}))$$

Es decir:

$$\frac{(\hat{\beta}_2 - \hat{\beta}_3) - (\beta_2 - \beta_3)}{\sqrt{\sigma^2(\tilde{Q}_{3,3} + \tilde{Q}_{4,4} - 2\tilde{Q}_{3,4})}} \sim N(0, 1)$$

Reemplazando  $\sigma^2$  por  $\hat{s}_R^2$  se tiene:

$$\frac{(\hat{\beta}_2 - \hat{\beta}_3) - (\beta_2 - \beta_3)}{\sqrt{\hat{s}_R^2(\tilde{Q}_{3,3} + \tilde{Q}_{4,4} - 2\tilde{Q}_{3,4})}} \sim t_{n-k-1}$$

Finalmente el estadístico del contraste cuando  $H_0$  es cierta es:

$$t_0 = \frac{\hat{\beta}_2 - \hat{\beta}_3}{\sqrt{\hat{s}_R^2(\tilde{Q}_{3,3} + \tilde{Q}_{4,4} - 2\tilde{Q}_{3,4})}} \sim t_{n-k-1}$$

```
beta_var = vcov(m1)
(t0 = (coef(m1)[3] - coef(m1)[4])/sqrt(beta_var[3,3] + beta_var[4,4] - 2*beta_var[3,4]))

##      mom_iq
## 0.9987263

# pvalor
2*pt(abs(t0), n - k - 1, lower.tail = F)

##      mom_iq
## 0.318489
```